



SAĞLIKTA YAPAY ZEKA YARIŞMASI

PROJE SUNUŞ RAPORU

GÖREV: Bilgisayarlı Tomografi (BT) Görüntülerinden
İnme Tespiti

Yarışma Eğitim Seviyesi: Üniversite ve Üzeri

Proje Adı:

Takım Adı: MAJESTY

Takım ID: 742174

Başvuru ID: 3627621

İçindekiler Tablosu

Takım Şeması.....	3
PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ.....	3
KULLANILAN VERİ SETİ VE ALGORİTMALAR.....	4
KULLANILAN VERİ SETİ: 5	
KULLANILAN ALGORİTMALAR VE GELİŞTİRME SÜRECİ: 5	
SONUÇLAR VE İNCELEME.....	7
Karşılaşılan Sorunlar ve Çözümler: 8	
Edinilen Tecrübeler: 8	
ÖZGÜNLÜK.....	8
REFERANSLAR.....	10

1. TAKIM ŞEMASI

Takımımız 3 Yapay Zeka Mühendisliği öğrencisi, 1 Bilgisayar Mühendisliği öğrencisi ve 1 Tıp öğrencisinden oluşmaktadır. Takımımızda 1 kişi veri seti bulmakta ve verileri ön işleme adımlarına tabi tutarak verileri sınıflandırma modellerine hazır hale getirmekle görevlidir. Görüntü verilerinin ön işlenmesinde (gürültü giderme, boyut standardizasyonu) ve bu kapsamda Python dili ile NumPy, Pandas ve scikit-learn gibi kütüphanelerde uzmanlaşmıştır. 2 kişi görüntü tabanlı sınıflandırma modellerinin geliştirilmesi ve eğitilmesinde görevlidir. CNN mimarileri, transfer learning ve görüntü sınıflandırma alanlarında ve PyTorch, TensorFlow, Keras kütüphanelerinde uzmanlaşmışlardır. 1 kişi geliştirilen modellerin test edilmesinde ve performanslarının analiz edilmesinde görevlidir. Model ölçüm metriklerinin (accuracy, f1 score, recall, precision) değerlendirilmesi, karşılaştırmalı model analizi ve hiperparametre optimizasyonu konularında uzmandır. 1 kişi görüntülerdeki inme bulgularının tıbbi açıdan analiz edilmesi ve model çıktılarının klinik doğruluk açısından değerlendirilmesinde görevlidir. Nörolojik görüntüleme, BT ve MR verilerinin klinik değerlendirilmesinde uzmanlaşmıştır.

2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ

1. Deep Learning in Ischemic Stroke Imaging Analysis: A Comprehensive Review (Cui et al., 2022)

Bu çalışmada literatürde medikal görüntüleme için yapay zeka çalışmalarının etkinliği araştırılmıştır. Dikkat çeken iki mimari bulunmuştur: Evrimsel Sinir Ağları (CNN) ve Tekrarlayan Sinir Ağları (RNN) örneği olan Uzun Kısa Süreli Bellek Ağları (LSTM). Bu mimarilerin bir kombinasyonu kullanılmış olup klasik yöntemlerle (örneğin lojistik regresyon, destek vektör makineleri) yapılan tahminlerden daha üstün olduğu bulunmuştur. Veri Seti: Özel izinli hastane verisi.

Sonuç: Derin öğrenme mimarilerinin klasik yöntemlerle karşılaştırılması yapılmıştır.

2. Hybrid UNet transformer architecture for ischemic stroke segmentation with MRI and CT datasets (Soh et al., 2023)

Bu çalışma akut intrakraniyal kanamaların (ICH) tespiti için transformer mimarisi ile birlikte UNet mimarisini birleştirme çözümünü sunmaktadır:

Transformers Kısmı:

Klasik transformer mimarisi görsel işlemeye uygun olmadığı için Vision Transformers (ViT's) kullanılmıştır. Bu transformer mimarisi orijinal transformer mimarisinden konumsal token'ları öğrenmesi ve decoder içermemesi ile ayrılır. ViT's bu çalışmada UNet'in yakaladığı yerel özelliklere genel dikkat bulguları ile katkı sağlaması için kullanılmıştır.

UNet Kısmı:

3 boyutlu CT verilerini birden fazla 3 boyutlu konvolüsyonlardan geçirip birleştirerek yerel bilgileri arar. Transformer mimarisinin dezavantajı olan, fazla

miktarda veriye bağımlılığa karşı kullanılmıştır. Böylelikle daha az veri ile hata azaltılmıştır.

Mimarilerin Birleştirilmesi:

UNet matrisleri ve transformers matrisleri, model içinde füzyon adı verdikleri katmanlarda birleştirilmiş ve bu birleştirilmiş matrisler tekrardan konvolüsyonlardan geçirilmişlerdir. Böylelikle $4 \times W \times H \times D$ boyutu ile giren bir matris maske halinde aynı boyutta çıkmaktadır.

Kullanılan veri seti: ISLES2018

Sonuç: Dice, 0.737 doğruluk oranı.

3. A deep learning algorithm for automatic detection and classification of acute intracranial hemorrhages in head CT scans (Wang et al., 2018)

Bu çalışma, akut intrakraniyal kanamaların (ICH) otomatik tespiti ve alt tiplerinin sınıflandırılması için geliştirilen üç aşamalı bir derin öğrenme sistemi sunmaktadır:

1. Aşama – 2D CNN Sınıflandırıcı ve Özellik Çıkarımı:

Her CT dilimi, öncelikle 8-bit gri tonlamalı görüntülere dönüştürülüp RGB kanallarında birleştirilmektedir. Bu görüntüler, SE-ResNeXt101, DenseNet169 ve DenseNet121 gibi popüler CNN mimarileri kullanılarak işlenip ve boyutları azaltılmaktadır. Bu aşamalarda erken tahmin yapıp veri ön işlemeden geçirilmektedir.

2.Aşama – Sequence Model 1 (Çift-Yönlü RNN – GRU):

İlk aşamada elde edilen özellik vektörleri, dilimler arasındaki mekânsal ilişkiyi yakalamak amacıyla bir dizi halinde getirilmekte Recursive networkler kullanılarak her dilim arasındaki bağıl ilişkiler araştırılmaktadır. Böylelikle model bağlam ile birleştirilmektedir.

3.Aşama – Sequence Model 2 (Ensemble ve Adaptif Ortalama):

Bu aşamada ilk 2 aşamadan elde edilen bilgiler 2 boyutlu bir vektörde birleştirilerek konvolüsyonel ve özyinelemeli nöral ağa gönderilmektedir. Ayrıca, dilim kalınlığı gibi ek meta veriler de bu aşamada modele entegre edilmektedir. Böylelikle tüm CT görüntülerinin bağıl ilişkileri ve tekil bilgisi son bir çıkarıma yönlendirilmektedir. Son olarak ilk aşamada elde edilen ön tahminler ve bu modelin tahminleri birleştirilerek sonuca ulaşılmaktadır.

Veri Seti: 2019-RSNA Brain CT Hemorrhage Challenge

Sonuç: AUC, 0.988 doğruluk oranı.

4. Deep Learning–Based Brain Computed Tomography Image Classification with Hyperparameter Optimization through Transfer Learning for Stroke (Chen et al., 2022).

Araştırmada transfer learning metodunun Ct görüntülemelerinde ne kadar etkili olduğu araştırılmıştır. Test amacıyla CNN-2, VGG-16, and ResNet-50 modelleri

kullanılmıştır. ResNet-50 ve CNN-2, VGG-16'ya kıyasla üstün performans göstermişlerdir ancak ResNet-50 modeli diğer iki modele kıyasla daha uzun hesaplama süresi gerektirmektedir. Çalışma 2 aşamaya ayrılabilir.

Veri Seti ve Veri Çoğaltma yöntemleri:

Veri seti farklı hastanelerden toplanmış olup 24769 görüntü içermektedir. CNN mimarisinin fazla veri ile daha iyi çalışması nedeniyle bu veri seti veri çoğaltma yöntemleriyle çoğaltılmıştır. Yansıtma, döndürme, kaydırma ve yakınlaştırma gibi yöntemler kullanılarak veri seti 2 katına çıkarılmıştır.

Eğitim:

NVIDIA V100 GPU ile transfer learning işlemi yapılmıştır. Eğitimler, CNN-2 8 dakika 19 saniye, VGG-16 1 dakika 58 saniye, ResNet-50 27 dakika 53 saniye şeklinde sonuçlanmıştır.

En iyi performans gösteren model ResNet-50 olup tüm inme kategorilerinde F1 0.99 skoruna ulaşmıştır.

5. Deep-learning based detection of vessel occlusions on CT-angiography in patients with suspected acute ischemic stroke (Brugnara et al., 2023)

Bu çalışma, akut iskemik inme şüphesi bulunan hastalarda BT anjiyografi görüntüleri üzerinden damar tıkanıklıklarını otomatik olarak tespit edebilen derin öğrenmeye dayalı bir yapay sinir ağı geliştirmeye odaklanıyor. Araştırmada, herhangi bir damar boyutu veya konum kısıtlaması olmaksızın, klinik senaryolara uygun şekilde tüm damar tıkanıklıklarını hızlıca (2 dakikadan kısa sürede) belirleyebilen bir sistem ortaya konulmuş.

Veri Seti: Heidelberg, FAST ve UKB olmak üzere 3 hastaneden elde edildi.

Yöntem: Tüm eğitim RetinaNet ile yapılmıştır.

Sonuç: AUROC 0.92 doğruluk oranı.

3. KULLANILAN VERİ SETİ VE ALGORİTMALAR

KULLANILAN VERİ SETİ

Projenin birinci görevine yönelik geliştirilen sınıflandırma modelinin eğitimi, Kaggle platformunda paylaşılan 2501 beyin CT görüntüsü bulunan "Brain Stroke CT Image Dataset" adlı açık erişimli veri seti kullanılarak gerçekleştirilmiştir. Model geliştirme sürecinde eğitim-veri ayrımı için %80 eğitim ve %20 doğrulama (validation) oranı uygulanmıştır. Böylece modelin aşırı öğrenme (overfitting) eğilimi göstermemesi ve genellenebilirliğinin artırılması hedeflenmiştir.

Eğitilen modelin gerçek dünya verileri üzerindeki performansını değerlendirmek amacıyla, test veri seti olarak TEKNOFEST 2021: İnme Veri Seti kullanılmıştır. Bu veri seti, daha önce modele tanıtılmamış olması sayesinde, modelin tutarlılığı ve genelleme kabiliyeti açısından objektif bir değerlendirme ortamı sunmuştur.

KULLANILAN ALGORİTMALAR VE GELİŞTİRME SÜRECİ

Projenin birinci görevinde (beyin BT görüntülerinden inme tespiti) çeşitli derin öğrenme tabanlı görüntü sınıflandırma algoritmaları üzerinde çalışılmış, bu algoritmaların performansları karşılaştırmalı olarak değerlendirilmiştir.

İlk aşamada, transfer learning yaklaşımı benimsenmiş ve EfficientNet ve VGG16 gibi önceden büyük ölçekli veri kümelerinde (ImageNet) eğitilmiş olan modeller kullanılarak temel ağlar üzerine ince ayarlamalar (fine-tuning) yapılmıştır. Bu modellerin son katmanları çıkarılarak yerine inme sınıflandırma görevine özgü yeni tam bağlantılı (fully connected) katmanlar eklenmiş ve böylece modellerin medikal görüntü sınıflamasına adapte edilmesi sağlanmıştır. Eğitim sürecinde modelin öğrenme kapasitesini dinamik biçimde optimize edebilmek için değişken öğrenme oranı (learning rate scheduling) stratejileri uygulanmıştır.

Geleneksel sınıflandırma modellerine ek olarak, nesne tespiti temelli bir yaklaşıma da başvurulmuştur. Geliştirdiğimiz yaklaşımda, beyin BT görüntülerinin tamamını tek bir sınırlayıcı kutu (bounding box) olarak işaretleyerek (0.5, 0.5, 1.0, 1.0 koordinatları) her görüntü "inme var" veya "inme yok" sınıf bilgisine atanmıştır. Bu yöntemle YOLOv8'in güçlü görsel öz nitelik çıkarma yeteneğinden faydalanarak etkin bir sınıflandırma modeli elde edilmiştir.

Modelimiz, semantik olarak inme bölgelerinin spesifik lokalizasyonunu yapmak yerine, tüm görüntüyü değerlendirerek inme varlığını tespit eden bir yaklaşım benimsemiştir. Bu sayede, klinik uygulamalarda ilk tarama aşamasında kullanılabilecek, yüksek doğruluklu ve hızlı çalışan bir destek sistemi geliştirilmesi hedeflenmiştir.

Model performansını artırmak ve overfitting riskini azaltmak amacıyla kapsamlı veri artırma (data augmentation) teknikleri uygulanmıştır. Bu teknikler arasında rastgele döndürme, parlaklık-kontrast ayarı, yatay/dikey çevirme ve Gaussian gürültü ekleme gibi işlemler yer almıştır.

Tüm bu süreç boyunca, beyin BT görüntüleri özenli bir ön işleme sürecinden geçirilmiş; boyut standardizasyonu, gri seviye dönüşümü ve normalize işlemleri gerçekleştirilerek modeller için en uygun formatta giriş verileri hazırlanmıştır.

Geliştirme sürecinde gerçekleştirilen bu çok yönlü algoritma deneyleri sayesinde hem sınıflandırma doğruluğu hem de medikal anlamlılık açısından güçlü ve güvenilir bir model mimarisi elde edilmiştir.

4. SONUÇLAR VE İNCELEME

Yapılan farklı model denemeleri sonucunda elde edilen performans metrikleri aşağıda sunulmuştur:

Model	Precision	Recall	F1 Score
EfficientNetB0	0.6758	0.9462	0.7885
VGG16	0.6784	0.8923	0.7708
InceptionResNetV2	0.6387	0.9385	0.7601
YOLOv5	0.7368	0.8525	0.7905
YOLOv8	0.9324	0.9431	0.9374

Elde edilen sonuçlar doğrultusunda, yüksek F1 skoru ve dengeli precision-recall performansı nedeniyle YOLOv8 modeli nihai model olarak seçilmiştir.

Modelin performansını değerlendirmek amacıyla %20 oranında ayrılmış doğrulama verisi üzerinde test senaryoları uygulanmış, ardından modelin genellenebilirliğini ölçmek amacıyla TEKNOFEST 2021: İhne Veri Seti kullanılarak eksternal validasyon gerçekleştirilmiştir.

Modelin doğrulama verisinde elde ettiği F1 skoru 0.95, eksternal test veri setindeki F1 skoru ise 0.93 olarak hesaplanmıştır. Bu sonuçlar, modelin farklı kaynaklardan gelen verilerde de yüksek doğrulukla çalışabildiğini göstermektedir. Ayrıca precision, recall, accuracy gibi diğer metrikler de incelenmiş ve genel performansın dengeli olduğu gözlemlenmiştir.

- Eğitim verisindeki farklı sınıf dengesizliklerini dengelemek için sınıf ağırlıkları ve veri çoğaltma (data augmentation) yöntemleri uygulanmıştır.
- Modelin erken durdurulması (early stopping) stratejisiyle overfitting'in önüne geçilmeye çalışılmıştır.

Karşılaşılan Sorunlar ve Çözümler:

Model geliştirme sürecinde ilk olarak overfitting problemi ile karşılaşılmıştır. Eğitim verisinde yüksek başarı elde edilmesine rağmen doğrulama verisindeki performans düşüklüğü bu durumu işaret etmiştir. Bu sorun, veri artırma teknikleri uygulanarak ve erken durdurma mekanizması eklenerek büyük ölçüde giderilmiştir.

Edinilen Tecrübeler:

Bu süreçte tıbbi görüntülerle çalışmanın yalnızca teknik değil, aynı zamanda klinik hassasiyet gerektirdiği anlaşılmıştır. Veri önışlemenin model eğitimi sırasında ve model başarısında kritik bir rol oynadığı, ayrıca farklı kaynaklardan gelen verilerle eksternal validasyon yapılmasının, model güvenilirliği ve tutarlılığı açısından büyük önem taşıdığı tecrübe edilmiştir.

5. ÖZGÜNLÜK

1) Sadece konvolüsyonlardan oluşan EfficientNet mimarisi ve konvolüsyonlara NN ekleyen VGG-16 mimarisi denenmiştir. Basitliklerine rağmen 2501 adet görüntüden oluşan görece küçük veri setimizle kabul edilebilir sonuçlar ortaya çıkarmışlardır.

2) YOLO aslında nesne tespiti modeli olduğu için etiketlere koordinat yazmamız gerekmektedir. Ancak problemi basitleştirmek için inme olan sınıflara tüm resmi kapsayacak koordinatlar verilmiştir. Böylelikle YOLO'nun sistemine uygun hale getirilmiştir.

3) YOLO-v8 transfer learning ile kullanılmıştır. Denediğimiz modeller arasında en iyi sonuç veren model YOLO olmuştur. YOLOv8'in anchor-free mimarisi projemizde kullanılan global sınıflandırma yaklaşımına uygun bir zemin oluşturmuştur ancak uygulamamızda inmenin bulunduğu spesifik bölgelerin lokalizasyonundan ziyade görüntüdeki inme varlığının tespitine odaklanılmıştır. Bu tercih, daha yüksek sınıflandırma doğruluğu elde edilmesine olanak sağlarken (%98.05 mAP50) projemizin temel hedefi ile uyumlu bir çözüm sunmuştur. Teknofest 2021 verisi incelendiğinde, verinin hasta bazlı olmayıp tekil görüntülerden oluştuğu gerçeği göz önüne alındığında YOLO tekil görüntülerle ve küçük veri seti boyutuyla oldukça iyi performans göstermiştir.

4) Kullanılan veri setinin görece küçük boyutu nedeniyle, modelin genellenebilirliğini artırmak ve aşırı öğrenme (overfitting) probleminin önüne geçmek amacıyla çeşitli veri çoğaltma (data augmentation) tekniklerinden yararlanılmıştır. Bu süreçte, görüntülerin rastgele döndürülmesi, yatay ve dikey eksenlerde çevrilmesi, parlaklık ve kontrast

seviyelerinin değiştirilmesi, yakınlaştırma-uzaklaştırma işlemleri uygulanması ve Gaussian gürültü eklenmesi gibi yöntemlerle verinin çeşitliliği artırılmıştır. Uygulanan bu teknikler sayesinde, sınırlı sayıdaki görüntüden farklı varyasyonlar üretilerek modelin farklı senaryolara karşı daha dayanıklı hale gelmesi sağlanmıştır. Bu da eğitim sürecinin daha dengeli ilerlemesini ve modelin test verisi üzerinde daha tutarlı sonuçlar üretmesini mümkün kılmıştır.

5) Eğitim sırasında ekstra konvolüsyon katmanları kullanarak segmentasyon problemlerine uygun veri setlerindeki segmente kısmı, ekstra katmanlardan geçirerek modele nereye bakması gerektiğine yardımcı olacak vektör hale getiren bir sistem geliştirilmesi düşünülmüştür. Ancak Teknofest 2021 verisinde sadece ikili (0-1) etiketleme kullanıldığı için bu fikir rafta kalmıştır.

6. REFERANSLAR

1. Cui, L., Fan, Z., Yang, Y., Liu, R., Wang, D., Feng, Y., Lu, J., & Fan, Y. (2022). Deep Learning in Ischemic Stroke Imaging Analysis: A Comprehensive Review. *BioMed research international*, 2022, 2456550. <https://doi.org/10.1155/2022/2456550>
2. Soh WK and Rajapakse JC (2023) Hybrid UNet transformer architecture for ischemic stroke segmentation with MRI and CT datasets. <https://www.frontiersin.org/articles/10.3389/fnins.2023.1298514/full>
3. Brugnara, G., Baumgartner, M., Scholze, E. D., Deike-Hofmann, K., Kades, K., Scherer, J., Denner, S., Meredig, H., Rastogi, A., Mahmutoglu, M. A., Ulfert, C., Neuberger, U., Schönenberger, S., Schlamp, K., Bendella, Z., Pinetz, T., Schmeel, C., Wick, W., Ringleb, P. A., Floca, R., ... Vollmuth, P. (2023). Deep-learning based detection of vessel occlusions on CT-angiography in patients with suspected acute ischemic stroke. *Nature communications*, 14(1), 4938. <https://doi.org/10.1038/s41467-023-40564-8>
4. Wang, X., Shen, T., Yang, S., Lan, J., Xu, Y., Wang, M., Zhang, J., & Han, X. (2021). A deep learning algorithm for automatic detection and classification of acute intracranial hemorrhages in head CT scans. *NeuroImage. Clinical*, 32, 102785. <https://doi.org/10.1016/j.nicl.2021.102785>
5. Kaggle. (n.d.). *Brain Stroke CT Image Dataset*. Retrieved from <https://www.kaggle.com/datasets/abedmk/brain-stroke-ct-image-dataset>
6. **T.C. Sağlık Bakanlığı.** (t.y.). *Yarışma Veri Seti 1. Oturum*. Açık Veri Portalı. Erişim adresi: <https://acikveri.saglik.gov.tr/Home/DataSetDetail/1>
7. Chen, Y. T., Chen, Y. L., Chen, Y. Y., Huang, Y. T., Wong, H. F., Yan, J. L., & Wang, J. J. (2022). Deep Learning-Based Brain Computed Tomography Image Classification with Hyperparameter Optimization through Transfer Learning for Stroke. *Diagnostics (Basel, Switzerland)*, 12(4), 807. <https://doi.org/10.3390/diagnostics12040807>